


# TESTES DE RAIZ UNITÁRIA

## Dickey-Fuller Aumentado - ADF

Teste bicaudal:



“drift”: Sem drift (intercepto) e sem tendência.

tau1->  $H_0$ : há raiz unitária; série não é estacionária

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)


Residuals:
    Min       1Q   Median       3Q      Max
-1.7338 -0.4964  0.5152  1.1874  3.4415

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1    -0.06815    0.19871  -0.343  0.73711
z.diff.lag -0.68147    0.20749  -3.284  0.00592 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.525 on 13 degrees of freedom
Multiple R-squared:  0.5661,    Adjusted R-squared:  0.4993
F-statistic: 8.479 on 2 and 13 DF,  p-value: 0.004398

Value of test-statistic is: -0.343

Critical values for test statistics:
    1pct  5pct 10pct
tau1 -2.66 -1.95 -1.6
```



Valor calculado para o teste

Valor crítico a 5% de significância, ou 95% de confiança

**SÉRIE NÃO É ESTACIONÁRIA**

“Drift”: Com drift (intercepto) e sem tendência.

tau2 ->  $H_0$ : há raiz unitária; série não é estacionária

phi1 ->  $H_0$ : série não é estacionária e não possui drift.

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression drift

call:  
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:

	Min	1Q	Median	3Q	Max
	-1.59422	-1.03477	-0.09777	0.69770	2.48573

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	1.5528	0.6024	2.578	0.0242 *
z.lag.1	-0.7227	0.3033	-2.382	0.0346 *
z.diff.lag	-0.3602	0.2134	-1.687	0.1173


---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.274 on 12 degrees of freedom  
Multiple R-squared: 0.717, Adjusted R-squared: 0.6698  
F-statistic: 15.2 on 2 and 12 DF, p-value: 0.0005137


Value of test-statistic is: -2.3824 3.4062

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.75	-3.00	-2.63
phi1	7.88	5.18	4.12



SÉRIE NÃO É  
ESTACIONÁRIA



SÉRIE NÃO É  
ESTACIONÁRIA  
E NÃO POSSUI  
DRIFT

# “Trend”: Com drift (intercepto) e com tendência. sãojudas

tau3 ->  $H_0$ : há raiz unitária; série não é estacionária.

phi2 ->  $H_0$ : série não é estacionária e não possui drift e não possui tendência.

phi3 ->  $H_0$ : série não é estacionária e não possui tendência.

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression trend

call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.5029	-0.8663	-0.0643	0.4765	2.5857

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	1.32512	0.79632	1.664	0.1243
z.lag.1	-0.82873	0.38961	-2.127	0.0569
tt	0.04494	0.09784	0.459	0.6549
z.diff.lag	-0.30943	0.24691	-1.253	0.2361

signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.318 on 11 degrees of freedom

Multiple R-squared: 0.7223, Adjusted R-squared: 0.6466

F-statistic: 9.538 on 3 and 11 DF, p-value: 0.002147


value of test-statistic is: -2.1271 2.1918 2.7568

critical values for test statistics:


	1pct	5pct	10pct
tau3	-4.38	-3.60	-3.24
phi2	8.21	5.68	4.67
phi3	10.61	7.24	5.91






**NÃO É ESTACIONÁRIA**



**NÃO É ESTACIONÁRIA  
NÃO POSSUI DRIFT  
NÃO POSSUI TENDÊNCIA**



**NÃO É ESTACIONÁRIA  
NÃO POSSUI TENDÊNCIA**




## Philips-Perron

O teste de Philipps-Perron realiza correções no teste de ADF para que seja consistente independentemente das ordens  $p$  e  $q$  do modelo.


O teste trona desnecessária a especificação de um modelo com ordem suficientemente autorregressivo para expurgar a correlação serial.

$H_0$ : há raiz unitária; série não é estacionária



### Phillips-Perron Unit Root Test

```
data: pdemprego1  
Dickey-Fuller = -4.5687, Truncation lag parameter = 2 p-value = 0.01
```



**SÉRIE É ESTACIONÁRIA**

Um dos problemas do teste de raiz unitária ADF é seu baixo poder ante a presença dos componentes de médias móveis.



Isso significa que o teste ADF não consegue rejeitar a hipótese nula para diversas séries econômicas que utilizam de médias móveis.

Dessa forma, Kwiatkowski, Phillips, Schmidt e Shin desenvolveram um teste para ser implementado complementarmente corrigindo essa distorção.

$H_0$ : série é estacionária

KPSS Test for Level Stationarity

data: pdemprego1  
KPSS Level = 0.38333, Truncation lag parameter = 0, p-value = 0.08434



**SÉRIE É ESTACIONÁRIA**

```
install.packages("forecast")  
install.packages(urca)  
install.packages("tseries")  
install.packages(readxl)  
install.packages("pwt8")  
library(forecast)  
library(tseries)  
library("urca")  
library(readxl)  
library(pwt8)
```

```
data("pwt8.0")  
view(pwt8.0)
```

```
br <- subset(pwt8.0, country=="Brazil",  
            select = c("rgdpna","emp","xr"))
```

```
colnames(br) <- c("PIB","Emprego","Câmbio")
```


```
PIB <- br$PIB[45:62]  
EMPREGO <- br$Emprego[45:62]  
CAMBIO <- br$Câmbio[45:62]  
Anos <- seq(from=1994, to=2011, by=1)
```




```
plot(PIB, type = "l")
pib <- ts(PIB, start = 1994, frequency = 1)
plot(cambio, main="Produto Interno Bruto",
     ylab="Milhoes de reais",
     xlab="Ano")
```

```
acf(pib)
pacf(pib)
reglinPIB <- lm(PIB ~ Anos)
reglinPIB
summary(reglinPIB)
plot(pib)
abline(reglinPIB, col="Blue")
```


Produto Interno Bruto




sãojudas



Series pib



Series pib



```
TesteADF_PIB_trend <- ur.df (pib, "trend", lags = 1)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

```
Test regression trend
```

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-58714 -12757   3226   22072  32907
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.824e+04  1.603e+05   0.238   0.816
z.lag.1      -3.099e-02  1.711e-01  -0.181   0.859
tt           6.662e+03  6.536e+03   1.019   0.328
z.diff.lag   -4.531e-01  2.869e-01  -1.580   0.140
```

```
Residual standard error: 28710 on 12 degrees of freedom
Multiple R-squared:  0.4465,    Adjusted R-squared:  0.3081
F-statistic: 3.226 on 3 and 12 DF,  p-value: 0.06102
```

```
value of test-statistic is: -0.1812 8.4963 4.7357
```

```
Critical values for test statistics:
```


```
      1pct   5pct  10pct
tau3 -4.38 -3.60 -3.24
phi2  8.21  5.68  4.67
phi3 10.61  7.24  5.91
```

tau3 ->  $H_0$ : há raiz unitária; série não é estacionária.


phi2 ->  $H_0$ : série não é estacionária e não possui drift e não possui tendência.

phi3 ->  $H_0$ : série não é estacionária e não possui tendência.


Série não é estacionária.



É estacionária, possui drift e possui tendência



É estacionária e possui tendência.



```
TesteADF_PIB_drift <- ur.df(pib, "drif", lags = 1)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

```
Test regression drift
```

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-64360 -12494   6997  14714  37034
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.147e+05  5.658e+04  -2.027   0.0637 .
z.lag.1       1.366e-01  4.713e-02   2.899   0.0124 *
z.diff.lag  -5.594e-01  2.676e-01  -2.090   0.0568 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 28750 on 13 degrees of freedom
Multiple R-squared:  0.3986,    Adjusted R-squared:  0.306
F-statistic: 4.307 on 2 and 13 DF,  p-value: 0.03671
```


```
value of test-statistic is: 2.8995 12.1882
```

```
critical values for test statistics:
```


```
    1pct    5pct   10pct
tau2 -3.75 -3.00 -2.63
phi1  7.88  5.18  4.12
```

tau2 ->  $H_0$ : há raiz unitária; série não é estacionária  
phi1 ->  $H_0$ : série não é estacionária e não possui drift

Série não é estacionária



Série é estacionária e possui drift



```
TesteADF_PIB_none <- ur.df(pib, "none", lags = 1)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

```
Test regression none
```

```
call:  
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:  
    Min       1Q   Median       3Q      Max  
-49445 -22629 -11100  13372  49484
```


```
Coefficients:  
             Estimate Std. Error t value Pr(>|t|)  
z.lag.1      0.04310    0.01058   4.072  0.00114 **  
z.diff.lag -0.31270    0.26353  -1.187  0.25515  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 31790 on 14 degrees of freedom  
Multiple R-squared:  0.6918,    Adjusted R-squared:  0.6477  
F-statistic: 15.71 on 2 and 14 DF,  p-value: 0.0002643
```

```
Value of test-statistic is: 4.0723
```

```
Critical values for test statistics:  
    1pct   5pct 10pct  
tau1 -2.66 -1.95 -1.6
```

tau1 ->  $H_0$ : há raiz unitária; série não é estacionária



Série é estacionária

`pp.test(pib)` $H_0$ : há raiz unitária; série não é estacionária

Phillips-Perron Unit Root Test


data: pib

Dickey-Fuller  $Z(\alpha) = -0.72766$ , Truncation lag parameter = 2, p-value = 0.9859

alternative hypothesis: stationary




Série não é estacionária





`kpss.test(pib)` $H_0$ : série é estacionária

KPSS Test for Level Stationarity

```
data: pib  
KPSS Level = 1.7145, Truncation lag parameter = 0, p-value = 0.01
```

**Série não é estacionária**

```
residuosPIB <- reglinPIB$residuals
reglinPIBres <- lm(residuosPIB ~ Anos)
plot(residuosPIB,type="l")
abline(reglinPIBres, col="Blue")
```



```
#Teste ADF

TesteADF_residuosPIB_trend <- ur.df(residuosPIB, "trend", lags = 1)
summary(TesteADF_residuosPIB_trend)

TesteADF_residuosPIB_drift <- ur.df(residuosPIB, "drift", lags = 1)
summary(TesteADF_residuosPIB_drift)

TesteADF_residuosPIB_none <- ur.df(residuosPIB, "none", lags = 1)
summary(TesteADF_residuosPIB_none)

#Teste Phillips-Perron

pp.test(residuosPIB)


#Teste KPSS

kpss.test(residuosPIB)
```



#Removendo Tendência por meio da diferença

```
pdPIB <- diff(PIB)
diferenca1PIB <- (data.frame(PIB[2:18],pdPIB))
DIFERENCAPIB <- ts(diferenca1PIB, start = 1994, frequency = 1)
plot(DIFERENCAPIB, plot.type="single", col=c("Black","Green"))
plot(pdePIB, type="l")
```



```
#Teste ADF

TesteADF_pdPIB_trend <- ur.df(pdPIB, "trend", lags = 1)
summary(TesteADF_pdPIB_trend)

TesteADF_pdPIB_drift <- ur.df(pdPIB, "drift", lags = 1)
summary(TesteADF_pdPIB_drift)

TesteADF_pdPIB_none <- ur.df(pdPIB, "none", lags = 1)
summary(TesteADF_pdPIB_none)

#Teste Phillips-Perron

pp.test(pdPIB)

#Teste KPSS

kpss.test(pdPIB)
```

```

arima113 <- arima(pib, c(1,1,3))

#ARMA
arima110 <- arima(pib, c(1,1,0))
arima111 <- arima(pib, c(1,1,1))
arima112 <- arima(pib, c(1,1,2))

arima210 <- arima(pib, c(2,1,0))
arima211 <- arima(pib, c(2,1,1))
arima212 <- arima(pib, c(2,1,2))
arima213 <- arima(pib, c(2,1,3))
#MA
arima011 <- arima(pib, c(0,1,1))
arima012 <- arima(pib, c(0,1,2))
arima013 <- arima(pib, c(0,1,3))
#AR
arima020 <- arima(pib, c(0,1,0))

#Escolher o melhor modelo com base no menor AIC/BIC
estimacoes <- list(arima113,arima110,arima111,
                    arima112,arima210,arima211,
                    arima212,arima213,arima011,arima011, arima012,
                    arima013,arima010)

AIC <- sapply(estimacoes, AIC)
AIC <- as.data.frame(AIC)
BIC <- sapply(estimacoes, BIC)
BIC <- as.data.frame(BIC)
Modelo <-c("arima113","arima110","arima111",
            "arima112","arima210","arima211",
            "arima212","arima213","arima011","arima011", "arima012",
            "arima013","arima010")

Resultados <- data.frame(Modelo,AIC,BIC)
view(Resultados)

```

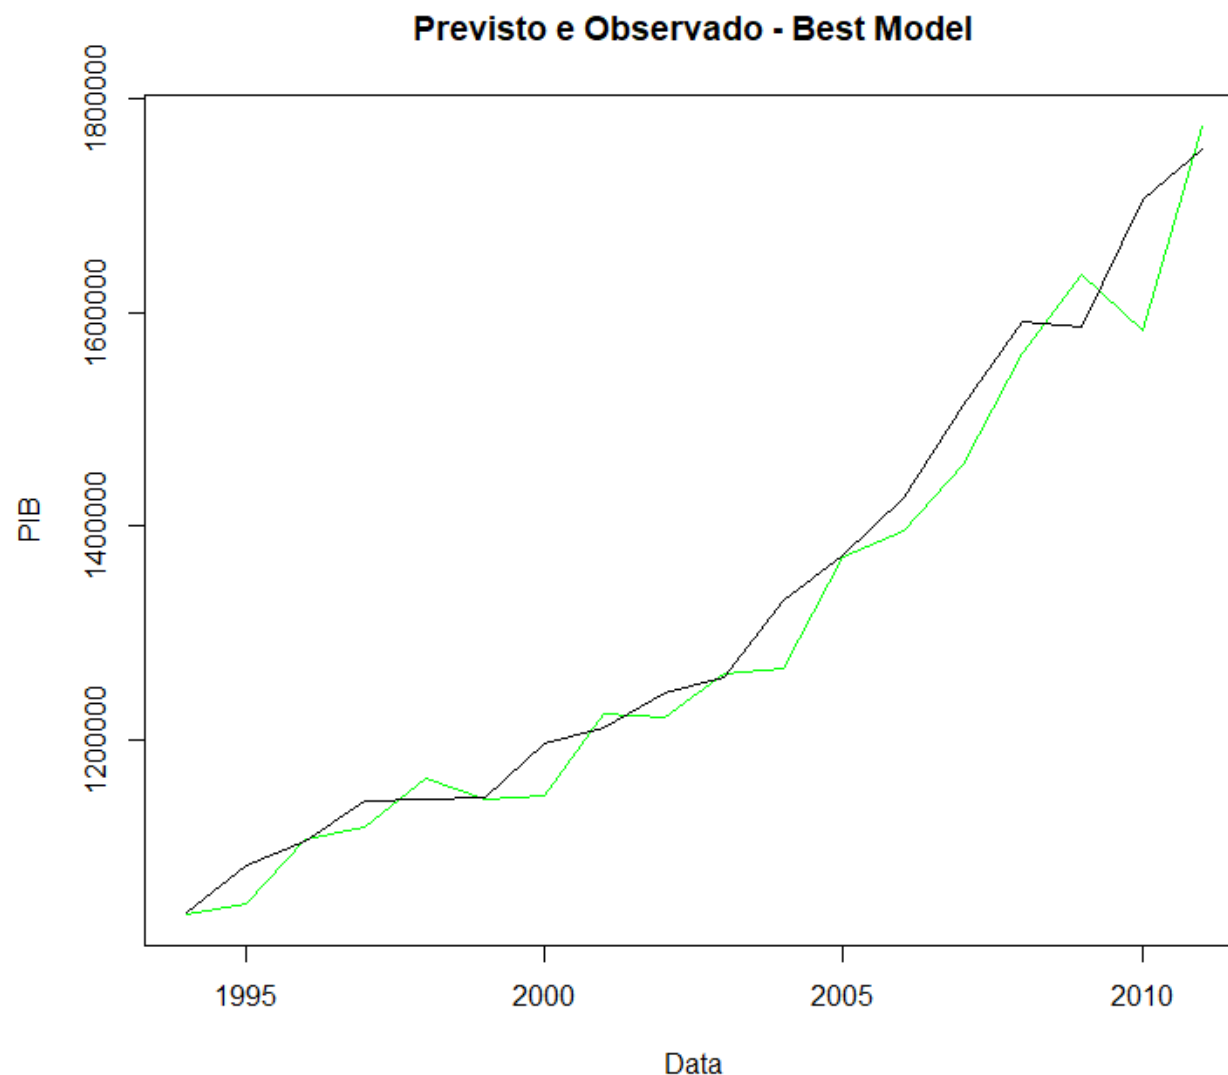
	Modelo	AIC	BIC
1	arima113	67.51313	71.37607
2	arima110	62.19765	63.74283
3	arima111	63.93166	66.24943
4	arima112	65.84527	68.93563
5	arima210	63.99329	66.31106
6	arima211	65.80967	68.90003
7	arima212	67.79937	71.66232
8	arima213	67.66381	72.29934
9	arima011	64.87238	66.41755
10	arima011	64.87238	66.41755
11	arima012	65.07276	67.39053
12	arima013	66.39055	69.48091

```
melhor_modelo <-  
previsto <- predict(melhor_modelo,6)  
view(previsto$pred)  
previsto1 <- forecast(melhor_modelo,6)  
previsto1
```

```
> previsto1
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
2012	1778711	1722915	1834506	1693379	1864042
2013	1793469	1689956	1896981	1635160	1951778
2014	1801772	1654434	1949110	1576438	2027106
2015	1806444	1619669	1993219	1520796	2092092
2016	1809072	1586865	2031280	1469235	2148910
2017	1810551	1556317	2064785	1421734	2199368

```
previsao01 <- forecast(melhor_modelo,6)
previstoBEST <- previsao01$fitted
modelo01 <- data.frame(previstoBEST,PIB)
modelo01 <- ts(modelo01,start = 1994, frequency = 1)
plot(modelo01, main="Previsto e Observado - Best Model",
     plot.type="single",
     xlab="Data",
     ylab="PIB",
     col=c("Green","Black"))
```



```
plot(forecast(melhor_modelo,6), main="Previsao do PIB - Melhor Modelo")
```

